



دانشکده مهندسی کامپیوتر

دانشگاه اصفهان

مستندات پروژه جبرخطی

میترا عمرانی ۹۹۳۶۱۳۰۴۷

خرداد 1402

در این پروژه عکس‌هایی را متناسب با دیتاست انتخابی google script images به برنامه می‌دهیم.

در ادامه به آن gaussian نویز اضافه می‌کنیم و سپس عملیات denoising را بر روی آن انجام می‌دهیم.

مستندات این پروژه شامل مثال‌ها و توابع پیاده‌سازی و دلیل انجام این کار است.

ابتدا به بررسی دلیل این نوع عملکرد می‌پردازیم:

اعمال نویز گاوسی روی یک تصویر و سپس حذف نویز می‌تواند کیفیت کلی تصویر را با کاهش تاثیر نویز بهبود بخشد. در اینجا به این دلیل است که این فرآیند معمولاً مورد استفاده قرار می‌گیرد:

۱. شبیه‌سازی شرایط دنیای واقعی:

نویز گاوسی نوعی نویز تصادفی است که به طور طبیعی در بسیاری از سیستم‌های تصویربرداری رخ می‌دهد. با اضافه کردن نویز گاوسی به یک تصویر، می‌توانیم نویزهایی را که ممکن است در سناریوهای دنیای واقعی وجود داشته باشد، مانند نویز حسگر دوربین یا نویز انتقال، شبیه‌سازی کنیم.

۲. بهبود جزئیات تصویر:

نویز اضافه شده به تصویر می‌تواند تغییرات با فرکانس بالا را ایجاد کند که ممکن است جزئیات یا بافت‌های خاصی را در تصویر بهبود بخشد. این می‌تواند تصویر را واضح‌تر یا از نظر بصری جذاب‌تر نشان دهد.

۳. حذف نویز برای کیفیت بهتر:

پس از افزودن نویز گاوسی، مرحله بعدی حذف نویز تصویر است. الگوریتم‌های حذف نویز برای کاهش تاثیر نویز و در عین حال حفظ جزئیات مهم تصویر طراحی شده‌اند. این الگوریتم‌ها تصویر را تجزیه و تحلیل می‌کنند و اجزای نویز را حذف می‌کنند و در نتیجه تصویری تمیزتر و از نظر بصری دلپذیرتر ایجاد می‌کنند.

که در این پروژه به ویژگی سوم توجه داشته‌ایم.

قسمت اصلی برنامه (mian) :
در این قسمت از توابع opencv برای باز کردن تصاویر و resize کردن آن‌ها استفاده شده است.

در قسمت بعد تابع `add_gaussian_noise(img, 0,50)` بر روی تصویر صدا زده می‌شود تا به آن نویز از نوع گوسی اضافه کند.
سپس تابع `denoise(noisy_image,5)` را بر روی تصویری که در مرحله‌ی قبل به آن نواز اضافه کردیم صدا می‌زنیم.

توابع به پنج دسته تقسیم می‌شوند.

۱. توابعی که نویز تولید می‌کنند :

۱. `box_muller_transform(mu, sigma)`:

این تابع تبدیل Box-Muller را پیاده‌سازی می‌کند، که روشی برای تولید جفتهای استاندارد مستقل اعداد تصادفی معمولی توزیع شده است. دو پارامتر μ (میانگین) و سیگما (انحراف استاندارد) نیاز دارد. در داخل تابع، دو عدد تصادفی $u1$ و $u2$ را با استفاده از تابع `random.random()` تولید می‌کند. سپس، معادلات تبدیل Box-Muller را برای محاسبه $z0$ و $z1$ ، که اعداد تصادفی معمولی توزیع شده استاندارد هستند، اعمال می‌کند. در نهایت، $z0$ و $z1$ را به ترتیب با سیگما و μ تغییر داده و تغییر می‌دهد و مقادیر تبدیل شده را برمی‌گرداند.

$$Z_0 = R \cos(\Theta) = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$$

$$Z_1 = R \sin(\Theta) = \sqrt{-2 \ln U_1} \sin(2\pi U_2).$$

۲. `add_gaussian_noise(image, mu=0, sigma=1)`:

این تابع نویز گاوسی را به تصویر اضافه می کند. یک تصویر را به عنوان ورودی و دو پارامتر اختیاری، μ (میانگین) و σ (انحراف استاندارد) می گیرد که به ترتیب 0 و 1 پیش فرض هستند. این تابع ابتدا تصویر را به کانال های قرمز، سبز و آبی (r, g, b) جدا می کند. سپس، روی هر پیکسل در تصویر تکرار می شود و با استفاده از تابع `box_muller_transform`، نویز گاوسی را به کانال مربوطه اضافه می کند. پس از اضافه کردن نویز، تابع مقادیر پیکسل را در محدوده معتبر 0 تا 255 برمی گرداند. در نهایت، تصویر اصلاح شده را با نویز گاوسی اضافه شده برمی گرداند.

۲. توابعی که که عملیات دینویز کردن را انجام می دهد.

۱. `denoise(image, threshold)`:

کد ارائه شده حذف نویز را بر روی یک تصویر با استفاده از یک آستانه مشخص انجام می دهد. تصویر را به کانال های رنگی خود (آبی، سبز و قرمز) تقسیم می کند و سپس فرایند حذف نویز را برای هر کانال به طور جداگانه اعمال می کند. فرایند حذف نویز شامل اعمال یک آستانه برای هر پیکسل در کانال است. اگر مقدار پیکسل زیر آستانه باشد، روی 0 (سیاه) و در غیر این صورت روی 255 (سفید) تنظیم می شود. این به حذف نویز از تصویر و افزایش وضوح آن کمک می کند. در نهایت، کانال ها دوباره با هم ادغام می شوند تا تصویر دینویز شده را تشکیل دهند. مقدار آستانه را نیز می توان به عبارتی همان تعداد بردارهای منفرد دانست، در توضیحات توابع بعدی به این موضوع پرداخته خواهد شد.

۲. `denoise_channel(channel, threshold)`:

`U, s, Vt = calculate_SVD1(channel)`

این خط تابعی را برای محاسبه تجزیه ارزش واحد (SVD) کانال ورودی فراخوانی می کند. SVD یک تکنیک فاکتورسازی ماتریسی است که یک ماتریس را به سه ماتریس جداگانه تجزیه می کند: U ، s ، Vt ماتریس های متعام هستند و s یک ماتریس مورب حاوی مقادیر منفرد است.

$$s[s > \text{آستانه}] = 0:$$

این خط یک آستانه را برای مقادیر (s) منفرد به دست آمده از SVD اعمال می‌کند. هر مقدار منفرد زیر آستانه مشخص شده روی 0 تنظیم می‌شود. این مرحله آستانه به حذف نویز از کانال کمک می‌کند. خواهیم دید با افزایش این مقدار که به منزله‌ی افزایش تعداد بردارهای منفرد است دینویزینگ بهتر انجام می‌شود، هرچند از حدی به بعدی تصویر ممکن است وضوح خود را از دست بدهد پس باید مقدار و تعداد مناسب این را بررسی کرد. این مورد در قسمت نتیجه در عکس‌ها بیان شده است.

$$\text{denoised_channel} = U \cdot \text{np.diag}(s) \cdot V^T$$

این خط با ضرب ماتریس‌های s ، U (تبدیل به یک ماتریس مورب با استفاده از np.diag) و V^T ، کانال حذف شده را بازسازی می‌کند. این عملیات ضرب به طور موثر مقادیر منفرد حذف شده را با ماتریس‌های متعامد اصلی ترکیب می‌کند.

۳. $\text{calculate_SVD1}(A)$:

مرحله ۱: ماتریس کوواریانس C را با گرفتن حاصل ضرب نقطه ای A با جابجایی آن $A.T$ محاسبه می‌کنیم.

مرحله ۲: تجزیه مقدار ویژه را بر روی ماتریس کوواریانس C انجام می‌دهیم. تابع `power_iteration` برای محاسبه مقادیر ویژه و بردارهای ویژه C فراخوانی می‌شود. همچنین می‌توانید از روش‌های دیگری مانند `qr_eigen` برای انجام تجزیه استفاده کنیم که هر دو در کد پیاده سازی شده‌اند. نکته قابل توجه این است که بسته به نوع انتخابی باید مقدار آستانه را نیز تنظیم کنیم تا بهترین نتیجه را بگیریم.

مرحله ۳: مقادیر ویژه و بردارهای ویژه را بر اساس مقادیر ویژه به ترتیب نزولی مرتب می‌کنیم. تابع `np.argsort` برای بدست آوردن شاخص‌های مرتب

شده استفاده می‌شود و سپس مقادیر ویژه و بردارهای ویژه بر این اساس بازآرایی می‌شوند.

مرحله ۴: مقادیر مفرد را با گرفتن قدر مطلق مقادیر ویژه و سپس جذر آن محاسبه کنید.

مرحله ۵: بردارهای منفرد چپ U را با ضرب A در بردارهای ویژه مرتب شده و تقسیم بر مقادیر منفرد محاسبه کنید.

مرحله ۶: بردارهای مفرد سمت راست VT را با جابجایی بردارهای ویژه مرتب شده عادی کنید.

در نهایت، تابع بردارهای منفرد چپ U ، مقادیر منفرد و بردارهای منفرد راست نرمال شده VT را برمی‌گرداند.

۳. توابعی که برای محاسبه‌ی مقادیر ویژه استفاده می‌شوند.

۱. $qr_eig(A, max_iter=50)$:

یک ماتریس A را به عنوان ورودی و یک پارامتر اختیاری max_iter می‌گیرد که حداکثر تعداد تکرارها را برای الگوریتم QR مشخص می‌کند. الگوریتم QR یک روش تکراری است که به طور مکرر از فرآیند گرم اشمیت برای تجزیه ماتریس A به یک ماتریس متعامد Q و یک ماتریس مثلثی بالا R استفاده می‌کند. این فرآیند حداکثر بار انجام می‌شود. پس از تکرارها، ماتریس A به ضرب R و Q به روز می‌شود که ماتریسی مشابه با A اصلی است اما با تخمین‌های ارزش ویژه بهبود یافته است. عناصر مورب ماتریس به روز شده A به عنوان مقادیر ویژه استخراج می‌شوند. برای هر مقدار ویژه، کد با کم کردن مقدار ویژه ضربدر ماتریس هویت از A ، یک ماتریس A_eig می‌سازد.

۲. `power_method(A, max_iter=50)`:

برای یافتن بردار ویژه مربوط به هر مقدار ویژه فراخوانی می شود. تابع `power_method` احتمالاً روش تکرار توان را برای یافتن بردار ویژه غالب یک ماتریس پیاده سازی می کند. مقادیر ویژه و بردارهای ویژه به صورت چند تایی بازگردانده می شوند و بردارهای ویژه به صورت ستون هایی در یک آرایه مرتب شده اند.

۳. `gram_schmidt(A)`:

فرآیند گرام اشمیت برای متعامد کردن یک ماتریس A و تجزیه آن به یک ماتریس متعامد Q و یک ماتریس مثلثی بالایی R پیاده سازی می کنیم.

$$\begin{aligned} \mathbf{u}_1 &= \mathbf{a}_1, & \mathbf{e}_1 &= \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|} \\ \mathbf{u}_2 &= \mathbf{a}_2 - \text{proj}_{\mathbf{u}_1} \mathbf{a}_2, & \mathbf{e}_2 &= \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|} \\ \mathbf{u}_3 &= \mathbf{a}_3 - \text{proj}_{\mathbf{u}_1} \mathbf{a}_3 - \text{proj}_{\mathbf{u}_2} \mathbf{a}_3, & \mathbf{e}_3 &= \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|} \\ &\vdots & &\vdots \\ \mathbf{u}_k &= \mathbf{a}_k - \sum_{j=1}^{k-1} \text{proj}_{\mathbf{u}_j} \mathbf{a}_k, & \mathbf{e}_k &= \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|} \end{aligned}$$

$$\begin{array}{c} \mathbf{A} \qquad \qquad \mathbf{Q} \qquad \qquad \mathbf{R} \\ \left[\begin{array}{c|c|c} \mathbf{a}_1 & \mathbf{a}_2 & \mathbf{a}_3 \end{array} \right] = \left[\begin{array}{c|c|c} \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \end{array} \right] \left[\begin{array}{ccc} \mathbf{e}_1^T \cdot \mathbf{a}_1 & \mathbf{e}_1^T \cdot \mathbf{a}_2 & \mathbf{e}_1^T \cdot \mathbf{a}_3 \\ 0 & \mathbf{e}_2^T \cdot \mathbf{a}_2 & \mathbf{e}_2^T \cdot \mathbf{a}_3 \\ 0 & 0 & \mathbf{e}_3^T \cdot \mathbf{a}_3 \end{array} \right] \\ \underbrace{\hspace{10em}}_{\text{Orthogonal Unit vectors}} \quad \underbrace{\hspace{10em}}_{\text{Upper Diagonal Matrix}} \end{array}$$

۴. توابع کاربردی بصورت کلی:


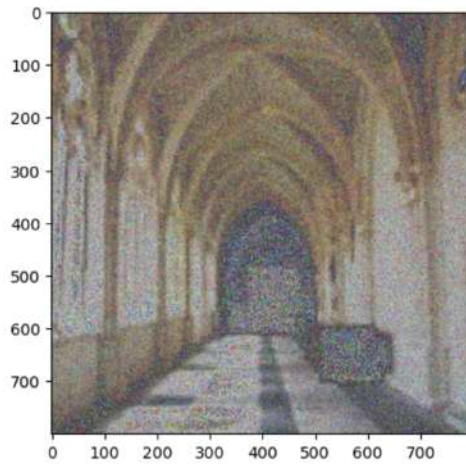
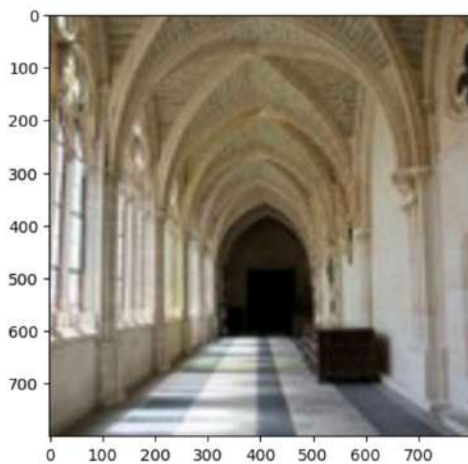
۱. `norm(vector)`:


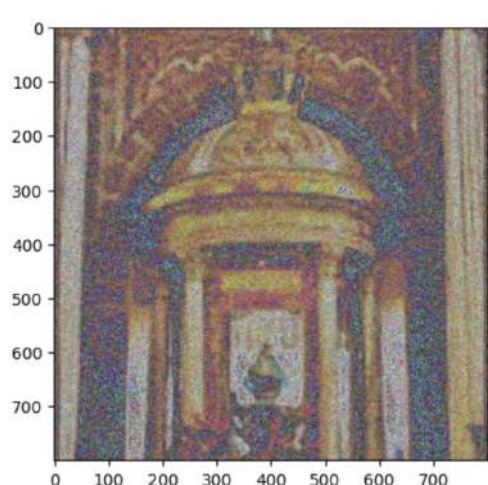
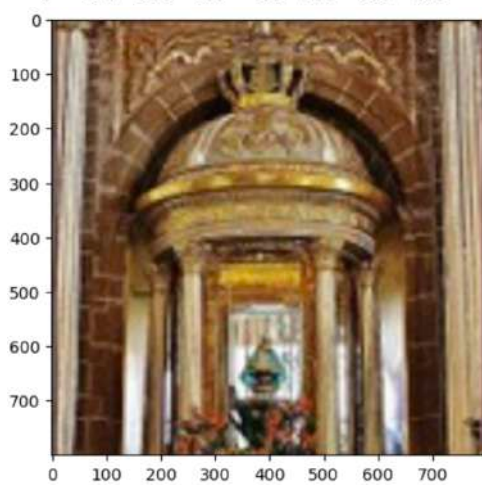
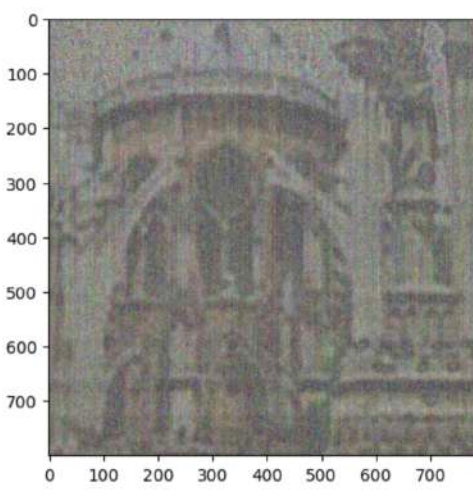
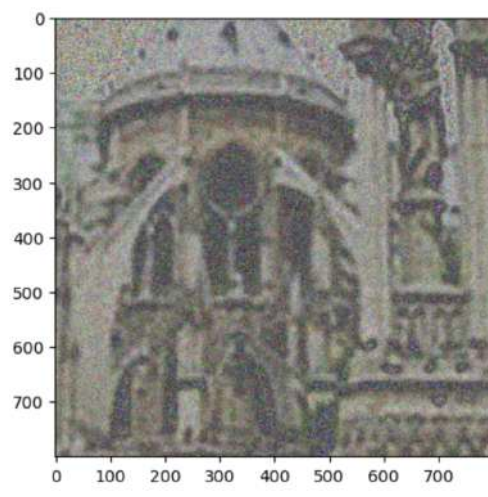
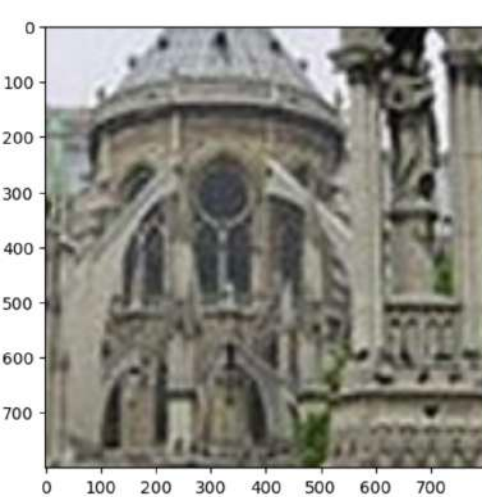
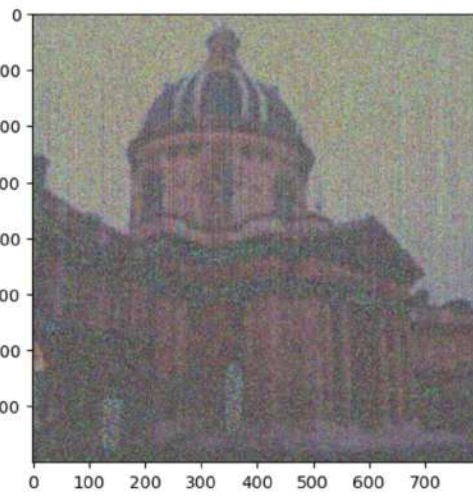
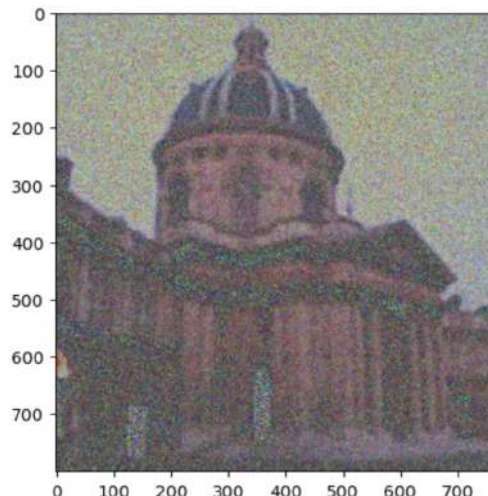
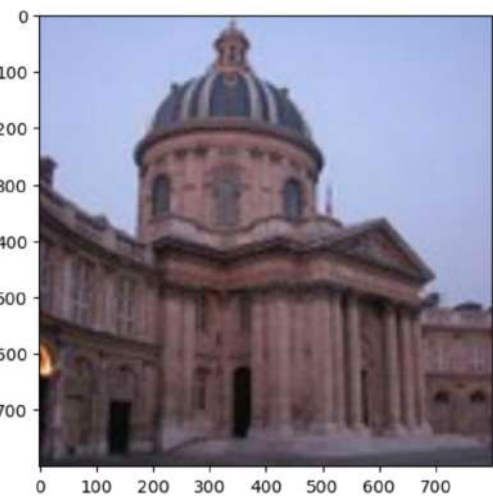
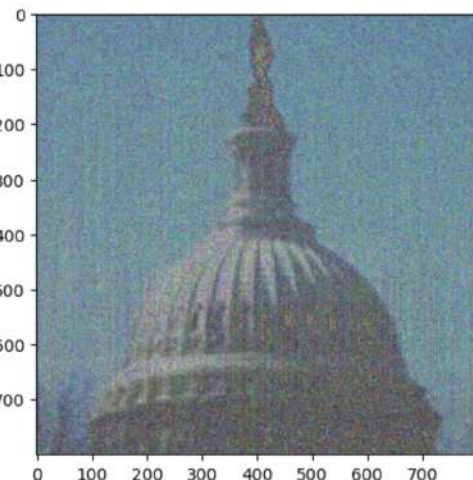
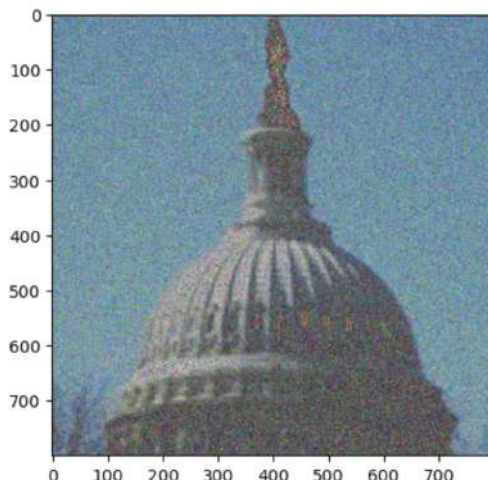
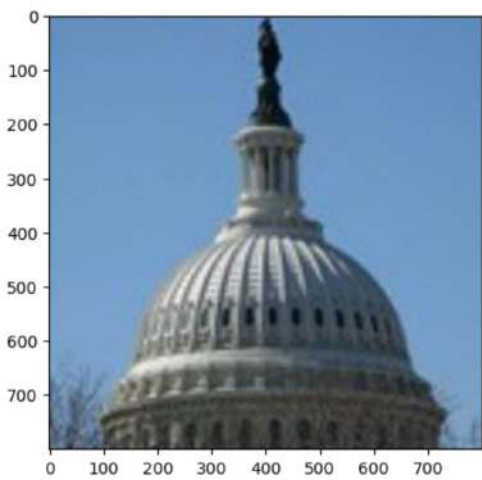
همان محاسبه‌ی نرم اقلیدسی، یا به اصطلاح نرم دوم است.

$$u = \begin{bmatrix} u_1 \\ u_2 \\ \dots \\ u_n \end{bmatrix}$$

$$\|u\|_2 = \sqrt{u_1^2 + u_2^2 + \dots + u_n^2}$$

قسمت نتایج و تصاویر:





در صورت استفاده از توابع دست پیاده سازی شده برای قسمت مقادیر ویژه چون در svd یک پارامتر طبق عنوان iteration داریم و برای نتیجه‌ی بهینه باید عدد آن بالا مانند 1000 و سطح آستانه 100 باشد.

در این حالت ممکن است پردازش طولانی شود اما نتایج بالا را به ما می‌دهد. در صورتی که در این تابع از محاسبه آماده‌ی مقادیر ویژه استفاده کند عدد آستانه اگر برابر 40 باشد تصاویر با کیفیت بهتر ارائه خواهند شد.

بطور کلی با افزایش سطح آستانه به عبارتی تعداد برداها و مقادیر منفرد دینویزینگ عکس بهتر می‌شود اما از حدی به بعد عکس دیگر قابل تشخیص نیست و همه قسمت‌های آن باهم ترکیب شده و فقط قسمت‌های جزئی و خاصی از آن مشخص می‌شود.